

PRODUCT REQUIREMENT DOCUMENT

Autonomous AI CS Engine for Travel Umroh

Production System Specification - Agent-Ready

AI Customer Service + RAG + Lead Database + Booking + Manual Payment Verification + Starsender/WABA-ready
Architecture

Item	Detail
Author	dausmhf Digital Agency
Status	Production System Draft - Agent-Ready
Primary Use Case	Travel Umroh customer service automation via WhatsApp
Active Channel	Starsender WhatsApp gateway
Prepared Channel	WhatsApp Business API / WABA
Payment Principle	Manual verification only. Sistem tidak boleh otomatis mengesahkan pembayaran.
Architecture Principle	Backend disiapkan lengkap dari awal. Modul belum aktif dikontrol lewat configuration dan feature flags, bukan rewrite source code.
Revision Note	Dokumen ini menutup gap audit dan temuan sisa: AI config model validation, idempotency storage, multi-pax limit, invoice expiry trigger, channel health check, KB conflict resolution, dan instruction contract untuk AI coding agent.

Arah Dokumen

Dokumen ini memakai pendekatan production-first. Semua kebutuhan sistem operasional didefinisikan sejak awal. Fitur yang belum dinyalakan tetap disiapkan di backend, database, adapter, dan konfigurasi agar nanti cukup diaktifkan tanpa bongkar source code. Dengan kata lain: developer tidak dibuat menambal kapal saat sudah berlayar.

Daftar Isi

1. Ringkasan Produk
2. Audit Resolution Matrix
3. Prinsip Desain Sistem
4. Business Problem & Value
5. Batasan Operasional
6. High-Level System Architecture
7. User Persona
8. User Flow
9. System Flow
10. AI Safety Guard & Error State
11. WhatsApp & Channel Adapter System
12. Database Capture System
13. Multi-Pax & Passenger Data Collection
14. RAG System Specification
15. Knowledge Base System
16. Brand Voice Specification
17. Configuration System
18. Follow-Up System
19. Conversation Summary System
20. Functional Requirements
21. Invoice PDF Specification
22. Payment Manual System
23. Human Handover System
24. Rate Limiting & Anti-Abuse
25. ERD & Data Model
26. File System & Repository Structure
27. API & Internal Service Contract
28. Queue & Worker Specification
29. Multi-Client Isolation
30. Deployment Specification
31. Security, Privacy & Compliance
32. Logging & Monitoring
33. Admin Operation SOP
34. Testing Scenario
35. Feature Activation Sequence
36. Developer Implementation Notes
37. AI Agent Prompt Contract
38. Definisi Eksplisit Ambiguitas
39. Constraint & Forbidden Patterns untuk Code Generation
40. Token Optimization & Cost Control System

1. Ringkasan Produk

Autonomous AI CS Engine for Travel Umroh adalah sistem customer service berbasis AI yang bekerja di kanal WhatsApp untuk menjawab calon jamaah, mengumpulkan database leads, memahami intent booking, membuat invoice, dan melakukan handover ke admin manusia ketika percakapan masuk area transaksi atau pembayaran.

Sistem ini production-first. Core backend, database, adapter channel, knowledge base, invoice, lead capture, follow-up, dan handover disiapkan dari awal. Saat ini channel aktif menggunakan Starsender, tetapi struktur backend wajib siap untuk WABA melalui perubahan konfigurasi dan adapter aktif saja.

AI bertugas sebagai mesin percakapan, ekstraksi intent, retrieval knowledge, dan asisten booking. Validasi pembayaran tetap manual oleh admin manusia. Mesin boleh cepat, tapi status uang tetap jangan diserahkan ke model bahasa yang kadang bisa salah mengeja nama hotel.

1.1 Objective Utama

- Menjawab pertanyaan calon jamaah 24/7 berdasarkan data resmi travel.
- Mengurangi kehilangan leads dari chat WhatsApp yang tidak sempat ditangani admin.
- Mengumpulkan database calon jamaah dari setiap chat masuk.
- Mendeteksi intent booking dan membuat data booking terstruktur.
- Mengelola data multi-pax dan passenger secara jelas tanpa memaksa calon jamaah mengirim dokumen sensitif ke bot.
- Membuat invoice otomatis berdasarkan data paket dan jumlah pax dari backend.
- Menerima bukti pembayaran sebagai evidence, lalu menyerahkan validasi ke admin manusia.
- Menyiapkan backend yang bisa pindah dari Starsender ke WABA tanpa perubahan source code utama.

1.2 Product Scope Besar

Area	Kebutuhan Sistem
AI CS	Menjawab informasi, follow-up ringan, memahami konteks, dan menjaga tone ramah islami.
RAG	Menjawab berdasarkan knowledge base travel, bukan karangan model. Retrieval memakai pgvector sebagai keputusan production.
Database Leads	Menyimpan identitas, nomor WA, minat paket, sumber chat, status, tag, dan riwayat percakapan.
Booking	Mengubah percakapan menjadi draft booking dengan data pemesan, jumlah pax, dan passenger summary.
Invoice	Membuat invoice PDF otomatis dari data backend dengan template yang sudah dispesifikasikan.
Payment Manual	Menerima bukti transfer, melakukan evidence triage, mengunci bot, lalu menyerahkan ke admin untuk cek mutasi manual.
Channel Adapter	Starsender aktif, WABA disiapkan, Telegram atau web widget dapat ditambahkan tanpa mengubah core logic.
Admin Control	Admin bisa ambil alih, mematikan bot, memberi label, update status lead/booking, dan mengembalikan kontrol ke bot.
Follow-Up	Membuat task follow-up otomatis untuk leads yang belum booking atau belum bayar.

2. Audit Resolution Matrix

Bagian ini menjadi jejak perbaikan agar developer tahu semua celah audit sudah ditutup. Bukan sekadar kosmetik dokumen, karena kosmetik tidak menolong saat webhook error jam sebelas malam.

Kode Audit	Perbaikan dalam Dokumen	Section
GAP-01	Ditambahkan AI Safety Guard, forbidden output, confidence threshold, fallback, dan response error state.	10
GAP-02	Ditambahkan schema dan contoh brand_voice.md.	16
GAP-03	Ditambahkan follow-up trigger, schedule, max attempt, template, dan stop rule.	18
GAP-04	Ditambahkan conversation summary generator, trigger, prompt, dan storage rule.	19
GAP-05	Ditambahkan rate limiting, anti-spam, flood handling, dan abuse state.	24
GAP-06	Ditambahkan multi-pax dan passenger data collection.	13
INK-01	Ditambahkan schema ai_config.json lengkap.	17.4
INK-02	Ditambahkan FR passenger data dan flow pengumpulan data jamaah.	13, 20
SCOPE-01	RAG diputuskan memakai PostgreSQL pgvector, dengan embedding, chunking,	14

Kode Audit	Perbaikan dalam Dokumen	Section
	ranking, dan threshold.	
SCOPE-02	Ditambahkan invoice PDF layout, field, numbering, logo, dan visual rule.	21
SCOPE-03	Ditambahkan urutan aktivasi feature flags tanpa memakai konsep fase produk.	35
PAY-01	Ditambahkan timeout dan escalation untuk evidence_received.	22.5
PAY-02	Ditambahkan triage bukti pembayaran invalid/non-payment file.	22.4
PAY-03	Ditambahkan bank account versioning dan audit trail.	22.6
PAY-04	Ditambahkan cancellation flow.	22.7
HANDOVER-01	Ditambahkan flow human_active kembali ke bot_active.	23.4
TECH-01	Vector store diputuskan: PostgreSQL + pgvector.	14.2
TECH-02	Ditambahkan queue/worker spec, retry, dan dead-letter.	28
TECH-03	Ditambahkan provider AI decision dan ai_config.	17.4
TECH-04	Ditambahkan multi-client isolation di database, storage, vector namespace, dan config.	29
TECH-05	Ditambahkan deployment Docker dan single-instance multi-client architecture.	30
SISA-01	ai_config menggunakan model default yang lebih aman dan wajib validasi model string ke provider sebelum deploy.	17.4
SISA-02	Ditambahkan idempotency storage, TTL, unique constraint, dan behavior duplicate webhook.	11.4
SISA-03	Ditambahkan batas maksimal pax yang boleh diproses bot dan rule handover rombongan besar.	13.4
SISA-04	Ditambahkan cron/worker trigger untuk invoice expired berdasarkan due_at + grace window.	22.8, 28
SISA-05	Ditambahkan response contract health_check dan perilaku sistem saat channel health gagal.	11.5
SISA-06	Ditambahkan conflict resolution knowledge base berdasarkan priority, effective_date, version, updated_at, dan source_type.	15.4

3. Prinsip Desain Sistem

Prinsip	Penjelasan
Backend prepared from day one	Semua tabel, service, adapter, queue, config, dan migration disiapkan dari awal walaupun sebagian belum aktif.
Configuration-first	Perubahan channel, model AI, client, rekening, prompt, dan fitur dilakukan dari config.
No hardcoded client data	Data travel tidak boleh tertanam di source code. Semua lewat database atau knowledge base.
Manual payment only	Sistem tidak mengesahkan pembayaran otomatis. Admin manusia wajib cek mutasi.
Channel-agnostic core	Core logic tidak peduli pesan datang dari Starsender, WABA, Telegram, atau web widget.
Database-first conversation	Setiap chat WA harus disimpan sebagai data, bukan hilang di riwayat WhatsApp.
AI as assistant, backend as source of truth	AI menjawab dan mengekstrak. Backend menghitung harga, membuat invoice, dan menentukan status.
Human handover is safety layer	Jika ada payment, komplain, kebingungan, confidence rendah, atau abuse, bot harus menyerahkan ke admin.
Tenant isolation	Data client tidak boleh tercampur pada database, vector store, storage, dan webhook routing.

Catatan Kritis

AI tidak boleh menjadi sumber kebenaran untuk harga, tanggal, status pembayaran, rekening, kuota, atau invoice. Semua keputusan transaksional harus berasal dari backend dan admin manusia.

4. Business Problem & Value

4.1 Masalah Bisnis Travel

- Banyak calon jamaah bertanya lewat WhatsApp di luar jam kerja.
- Admin sering membalas lambat, terutama malam hari.
- Pertanyaan repetitif menghabiskan waktu admin: harga, jadwal, hotel, maskapai, fasilitas, DP, syarat.
- Database calon jamaah sering hanya tersimpan di WhatsApp, tidak masuk CRM atau database.
- User yang sudah tertarik bisa hilang karena tidak ada follow-up terstruktur.
- Owner travel sulit membaca pipeline karena data chat tercecer.

4.2 Nilai Produk


Pihak	Value
Owner Travel	Leads lebih cepat tertangani, database lebih rapi, admin lebih fokus closing.
Admin Travel	Pertanyaan dasar dijawab AI, admin masuk saat user sudah lebih matang.
Calon Jamaah	Mendapat jawaban cepat, jelas, sopan, dan sesuai data paket.
Agency	Memiliki produk B2B high-value yang bisa dijual sebagai AI CS + database + automation system.


5. Batasan Operasional

Dokumen ini mendefinisikan sistem produksi secara penuh. Namun ada batasan prinsip yang tidak boleh dilanggar, terutama pada pembayaran, data sensitif, dan klaim informasi.

Area	Aturan
Payment	Pembayaran selalu diverifikasi manual oleh admin. Tidak ada auto-paid dari AI.
Rekening	Bot hanya boleh menyebut rekening dari payment_config versi aktif.
Harga	Harga dihitung backend dari database paket. AI tidak boleh menghitung sendiri jika data tidak jelas.
Kuota	Sisa seat hanya boleh disebut jika tersedia di database. Jika tidak ada, arahkan ke admin.
Dokumen sensitif	KTP, paspor, dan dokumen pribadi diarahkan ke admin atau sistem upload aman.
WhatsApp	Saat ini memakai Starsender, namun desain backend wajib WABA-ready.
Source code	Penambahan client/channel/fitur tidak boleh menuntut rewrite core logic.
AI output	Semua output AI melewati safety guard sebelum dikirim ke user.

6. High-Level System Architecture





6.1 Layer Architecture

Layer	Tanggung Jawab
Channel Adapter	Menyambungkan Starsender/WABA/Telegram ke core system.
Ingestion	Menerima, membersihkan, deduplikasi, rate limit, dan menyimpan semua pesan masuk.
Identity Resolver	Menghubungkan nomor WA dengan contact/lead yang sudah ada.
Conversation Engine	Mengelola status thread, memory, lock, summary, dan routing.
AI Engine	Intent detection, RAG, extraction, response generation, dan safety guard.
Business Services	Lead, booking, passenger, invoice, payment evidence, handover, follow-up.
Database	Menyimpan leads, messages, bookings, invoices, events, logs, vectors.
Queue Worker	Menjalankan retry, follow-up, notification, invoice job, summary refresh.
Admin Ops	Control admin, notifikasi, takeover, payment verification, status update.

7. User Persona

Persona	Kebutuhan	Sistem Harus Menyediakan
Calon Jamaah	Informasi cepat, jelas, terpercaya, dan tidak terasa robotik.	AI CS dengan RAG, bahasa ramah islami, dan fallback ke admin.
Admin Travel	Data calon jamaah matang dan tidak tercecer.	Lead profile, conversation summary, booking data, payment alert.
Owner Travel	Pipeline, database, dan respon 24/7.	Database leads, status funnel, log chat, dan sistem siap WABA.
Agency Operator	Setup banyak client tanpa rewrite code.	Multi-client config, tenant isolation, adapter abstraction, feature flags.

8. User Flow

8.1 Flow Informasi Paket

User bertanya di WhatsApp

- > pesan masuk via Starsender/WABA adapter
- > sistem simpan message dan contact
- > cek rate limit dan conversation status
- > intent = ask_package / ask_price / ask_facility
- > RAG mencari data paket relevan
- > AI membuat jawaban berdasarkan context
- > safety guard memvalidasi output
- > jawaban dikirim ke WhatsApp
- > lead profile diperbarui: interest, package, tag, last_intent

8.2 Flow Booking

User menunjukkan minat booking

- > intent = booking_intent
- > entity extraction: nama, nomor, paket, pax
- > sistem cek field wajib pemesan
- > sistem cek apakah multi-pax perlu passenger summary
- > jika kurang, AI bertanya satu per satu
- > jika lengkap, backend membuat booking draft
- > backend membuat invoice PDF
- > invoice dikirim ke user
- > status lead = invoice_sent
- > status conversation = waiting_payment_evidence
- > follow-up task dibuat jika user belum kirim bukti

8.3 Flow Pembayaran Manual

User mengirim gambar/file bukti transfer

- > sistem melakukan evidence triage
- > jika kemungkinan payment evidence, file disimpan
- > bot membalas acknowledgement tanpa validasi
- > conversation dikunci dari auto-reply
- > admin notification urgent dikirim
- > jika admin tidak response, escalation retry berjalan
- > admin cek mutasi bank secara manual
- > admin update status: paid / pending / invalid / cancelled
- > admin mengembalikan bot jika percakapan sudah aman

9. System Flow

9.1 Incoming Message Processing

1. Payload diterima dari Starsender atau WABA adapter.
2. Payload dinormalisasi menjadi format internal MessageEvent.
3. Sistem menjalankan idempotency check agar webhook dobel tidak membuat pesan ganda.
4. Sistem menjalankan rate limit check per client, nomor, dan conversation.
5. Sistem mencari atau membuat Contact berdasarkan nomor WhatsApp.
6. Sistem mencari atau membuat Conversation berdasarkan contact dan client.
7. Raw message dan normalized message disimpan ke database.
8. Sistem cek conversation status dan bot_enabled.
9. Jika status human_active, handover_required, atau abuse_limited, pesan hanya disimpan dan admin dapat melihatnya.
10. Jika pesan berupa file/gambar dan status sedang menunggu pembayaran, jalankan payment evidence triage.
11. Jika pesan berupa teks, sistem menjalankan intent detection dan RAG.
12. Response melewati safety guard sebelum dikirim.
13. Lead profile, tags, last_intent, dan lifecycle stage diperbarui.

9.2 Outgoing Message Processing

1. AI atau backend membuat response payload.
2. Payload dicek oleh safety guard.
3. Jika response mengandung harga/rekening, validasi ke database/config.
4. Jika confidence rendah atau terdapat output terlarang, sistem memakai fallback response.
5. Message dikirim lewat adapter channel yang sama.
6. Outgoing message disimpan ke database.
7. Jika gagal kirim, sistem membuat retry event dan notifikasi error internal.

10. AI Safety Guard & Error State

Safety guard adalah layer wajib sebelum jawaban AI dikirim. Tugasnya sederhana tapi penting: mencegah model menjawab seperti sales mabuk optimisme. Semua response harus melewati validasi policy, data consistency, dan confidence threshold.

10.1 AI Response State

State	Kondisi	Action
safe_response	Jawaban sesuai context, tidak mengandung forbidden output.	Kirim ke user.
missing_context	Pertanyaan butuh data yang tidak ada di knowledge base.	Fallback ke admin.
low_confidence	Intent confidence < 0.70 atau retrieval score < threshold.	Minta klarifikasi atau handover.
policy_violation	Output mengandung klaim pembayaran, rekening tidak valid, atau janji berlebihan.	Block response dan gunakan fallback.
calculation_required	User meminta total harga atau invoice.	Delegasikan ke backend calculator/invoice service.
sensitive_data	User mengirim atau diminta data sensitif seperti paspor/KTP.	Arahkan ke admin atau secure upload.
abuse_detected	Flood, spam, kata kasar ekstrem, atau bot attack.	Rate limit, mute sementara, notify admin.

10.2 Forbidden AI Output

- Mengonfirmasi pembayaran: "sudah lunas", "pembayaran berhasil", "transfer valid".
- Menyebut rekening yang tidak berasal dari payment_config versi aktif.
- Membuat harga, jadwal, hotel, maskapai, promo, atau kuota tanpa data backend.
- Menjamin visa pasti diterima atau keberangkatan pasti tanpa syarat.
- Menjawab dokumen sensitif secara bebas tanpa admin atau secure upload.
- Menyuruh user transfer ke rekening personal/admin yang tidak terdaftar.
- Membuat janji refund, reschedule, atau cancellation di luar terms resmi.

10.3 Confidence & Fallback Threshold

Signal	Threshold	Action
Intent confidence	≥ 0.80	Lanjutkan flow normal.
Intent confidence	0.60 - 0.79	Minta klarifikasi singkat.
Intent confidence	< 0.60	Fallback ke admin atau safe answer.
Top retrieval score	≥ 0.75	Boleh jawab dengan context.
Top retrieval score	0.55 - 0.74	Jawab terbatas dan tawarkan admin.
Top retrieval score	< 0.55	Jangan jawab detail. Arahkan admin.
Payment-related message	Any confidence	Tidak validasi otomatis. Trigger manual flow.

10.4 Default Fallback Messages

[missing_context]

Untuk informasi itu saya bantu teruskan ke admin ya Ayah/Bunda, agar jawabannya lebih pasti sesuai data terbaru travel.

[low_confidence]

Biar tidak salah arah, boleh saya pastikan dulu Ayah/Bunda sedang menanyakan paket yang mana?

[payment_related]

Baik Ayah/Bunda, bukti pembayaran sudah kami terima. Untuk keamanan transaksi, admin akan cek mutasi rekening resmi terlebih dahulu.

[sensitive_data]

Untuk data dokumen pribadi, nanti admin akan bantu proses melalui jalur yang lebih aman ya Ayah/Bunda.

11. WhatsApp & Channel Adapter System

Core system tidak boleh bergantung langsung pada Starsender. Starsender hanya adapter. Ketika nanti pindah ke WABA, core system tetap sama. Kalau core logic bercampur dengan API vendor, migrasi channel nanti akan menjadi ritual pengusiran bug.

11.1 Channel Adapter Interface

Method	Fungsi
send_text(conversation_id, text)	Mengirim pesan teks ke user.
send_file(conversation_id, file_path, caption)	Mengirim invoice atau file lain.
parse_incoming(payload)	Mengubah payload vendor menjadi MessageEvent internal.
mark_read(conversation_id)	Opsional, menandai pesan terbaca.
get_sender_identity(payload)	Mengambil nomor WA, nama, dan channel user id.
validate_signature(payload)	Validasi webhook jika provider mendukung.
health_check()	Mengecek adapter aktif dan credential valid.

11.2 Supported Adapter

Adapter	Status Sistem	Catatan
StarsenderAdapter	Active	Digunakan sementara untuk koneksi WhatsApp.
WabaCloudAdapter	Prepared	Disiapkan untuk WhatsApp Business API.
TelegramAdapter	Prepared	Dipakai untuk admin notification atau demo.
WebWidgetAdapter	Prepared	Untuk chat widget website jika dibutuhkan.

11.3 Normalized MessageEvent

```
{
  "event_id": "evt_001",
  "idempotency_key": "starsender:message_id_abc",
  "client_id": "travel_alfalah",
  "channel": "starsender",
  "channel_account_id": "wa_001",
  "sender_name": "Muhammad Firdaus",
  "sender_phone": "628123456789",
  "message_type": "text|image|file|audio|location",
  "text": "Saya mau tanya paket Oktober",
  "file_url": null,
  "raw_payload": {},
  "received_at": "2026-07-30T21:15:00+07:00"
}
```

11.4 Idempotency Storage & Duplicate Webhook Behavior

Setiap webhook incoming harus melewati idempotency check sebelum membuat message, contact update, booking, invoice, atau queue task. Ini mencegah provider mengirim ulang payload lalu sistem menggandakan chat, invoice, atau notifikasi. Manusia sudah cukup menggandakan masalah tanpa bantuan webhook.

Item	Specification
Storage table	webhook_idempotency_keys
Unique key	client_id + channel + idempotency_key
TTL	30 hari untuk message event; 90 hari untuk payment/invoice related event.
Insert behavior	Insert key lebih dulu dalam transaksi database. Jika gagal karena unique constraint, proses dihentikan sebagai duplicate.
Duplicate behavior	Return HTTP 200/OK ke provider, tetapi tidak membuat message baru, tidak mengirim response baru, dan tidak membuat queue task baru.
Stored fields	id, client_id, channel, idempotency_key, event_type, first_seen_at, last_seen_at, duplicate_count, raw_payload_hash, related_message_id.
Cleanup	Daily cleanup worker menghapus key yang melewati TTL dan tidak terkait payment/invoice aktif.

```
CREATE TABLE webhook_idempotency_keys (  
  id UUID PRIMARY KEY,  
  client_id UUID NOT NULL,  
  channel VARCHAR(50) NOT NULL,  
  idempotency_key VARCHAR(255) NOT NULL,  
  event_type VARCHAR(80) NOT NULL,  
  first_seen_at TIMESTAMPTZ NOT NULL DEFAULT now(),  
  last_seen_at TIMESTAMPTZ NOT NULL DEFAULT now(),  
  duplicate_count INTEGER NOT NULL DEFAULT 0,  
  raw_payload_hash VARCHAR(128),  
  related_message_id UUID,  
  expires_at TIMESTAMPTZ NOT NULL,  
  UNIQUE (client_id, channel, idempotency_key)  
);
```

11.5 Channel health_check() Contract

health_check() wajib dipanggil saat service startup, periodic scheduler, dan sebelum pergantian adapter aktif. Tujuannya memastikan credential, webhook, dan kemampuan kirim pesan masih sehat.

Field	Type	Meaning
status	healthy degraded unhealthy	Kesehatan adapter.
provider	string	starsender, waba, telegram, atau adapter lain.
can_send_message	boolean	True jika adapter dapat mengirim pesan.
can_receive_webhook	boolean	True jika webhook route/secret valid.
credential_valid	boolean	True jika token/API key valid.
latency_ms	integer	Latency ping/test request.
checked_at	datetime	Waktu health check.
error_code	nullable string	Kode error provider jika gagal.
recommended_action	string	Contoh: rotate token, pause adapter, fallback to manual.

Kondisi	System Behavior
healthy	Adapter boleh menerima dan mengirim pesan.
degraded	Pesan tetap diterima, tetapi outgoing message masuk queue retry dan admin diberi warning.
unhealthy saat startup production	Service tidak boleh start sebagai active sender. Ingestion route boleh aktif jika aman.
unhealthy saat runtime	Pause auto-reply untuk client/channel terkait, simpan semua incoming message, notify admin/ops.

12. Database Capture System

Karena chat terjadi langsung di WhatsApp, sistem wajib menyimpan database sendiri. Jangan hanya mengandalkan riwayat WA. WhatsApp itu tempat ngobrol, bukan CRM. Peradaban bisnis memang sering dimulai dari kebingungan sederhana seperti ini.

12.1 Data yang Harus Ditangkap

Kategori	Data
Contact	Nama, nomor WA, channel id, kota, sumber masuk, consent status.
Lead Profile	Interest paket, budget range, jumlah pax, jadwal minat, status funnel, tags.
Conversation	Status bot, channel, last message, assigned admin, summary.
Message Log	Semua pesan masuk dan keluar, tipe pesan, file, timestamp.
Intent History	Intent per pesan, confidence, extracted entities.
Booking	Paket, pax, nama pemesan, nomor HP, total amount, status.
Passenger Summary	Jumlah jamaah, nama awal jika tersedia, data lengkap jika admin meminta.
Invoice	Nomor invoice, file PDF, nominal, due date, status.
Payment Evidence	File bukti transfer, caption, status validasi manual.
Follow-up	Reminder, jadwal follow-up, admin owner, hasil follow-up.

12.2 Lead Lifecycle Stage

Stage	Makna
new_lead	Kontak baru masuk.

Stage	Makna
engaged	User bertanya dan membalas.
interested_package	User menunjukkan minat pada paket tertentu.
booking_intent	User menyatakan ingin daftar/booking.
data_collection	Sistem sedang mengumpulkan data booking.
invoice_sent	Invoice sudah dikirim.
payment_evidence_received	Bukti transfer diterima, menunggu admin.
manual_verification	Admin sedang cek mutasi.
paid	Admin menandai pembayaran valid.
lost	Lead tidak lanjut.
closed	Percakapan selesai.
abuse_limited	Nomor dibatasi karena spam/flood.

12.3 Database Capture Rules

- Setiap nomor WhatsApp harus menjadi satu Contact unik per client.
- Setiap chat masuk harus membuat atau memperbarui Lead Profile.
- Riwayat pesan tidak boleh hilang meskipun bot dimatikan.
- Intent dan entity hasil AI disimpan untuk analisis pipeline.
- Data booking tidak boleh hanya berada di chat; wajib masuk tabel Booking.
- Invoice harus memiliki relasi ke Booking dan Contact.
- Payment evidence harus disimpan, tetapi status validasi hanya dapat diubah oleh admin manusia.

13. Multi-Pax & Passenger Data Collection

Booking umroh sering bukan satu orang. Satu pemesan bisa membawa pasangan, orang tua, anak, atau rombongan kecil. Sistem harus membedakan data pemesan, jumlah pax, dan data passenger. Kalau tidak, invoice bisa benar tapi administrasi jadi ladang ranjau.

13.1 Data Pemesan vs Data Jamaah

Data	Dikumpulkan Oleh AI?	Waktu Pengumpulan	Catatan
Nama pemesan	Ya	Sebelum invoice	Wajib untuk invoice.
Nomor HP pemesan	Ya	Sebelum invoice	Wajib untuk contact dan invoice.
Jumlah pax	Ya	Sebelum invoice	Dipakai untuk kalkulasi total.
Nama passenger per pax	Opsional	Sebelum atau setelah invoice	Cukup first name/full name jika user sudah siap.
KTP/Paspor	Tidak lewat AI bebas	Setelah admin takeover/secure upload	Data sensitif. Jangan diminta bebas oleh bot.
Tanggal lahir/gender	Opsional	Setelah booking matang	Sebaiknya admin/secure form.

13.2 Multi-Pax Flow

User: Saya mau booking 3 orang.

Bot:

1. Ambil nama pemesan.
2. Ambil nomor HP pemesan.
3. Konfirmasi paket dan jumlah pax.
4. Tanya opsional: "Nama jamaah lainnya mau dicatat sekarang atau nanti dibantu admin?"
5. Jika user siap, simpan passenger placeholders.
6. Jika user belum siap, invoice tetap bisa dibuat berdasarkan pax.
7. Data dokumen lengkap diarahkan ke admin/secure form.

13.3 Passenger Record State

Status	Makna
placeholder	Pax sudah dihitung, nama jamaah belum lengkap.
name_collected	Nama jamaah sudah ada, dokumen belum.
admin_required	Butuh admin untuk data sensitif.
completed	Data jamaah lengkap sesuai kebutuhan travel.
cancelled	Passenger dibatalkan/dikurangi.

13.4 Max Pax Conversational Limit

Bot boleh membantu multi-pax, tetapi tidak boleh memaksa percakapan WhatsApp menjadi formulir rombongan 30 orang. Untuk booking grup besar, bot cukup menangkap summary dan menyerahkan ke admin.

Jumlah Pax	Bot Behavior
1 pax	Bot kumpulkan data pemesan dan boleh tawarkan data jamaah utama.
2-5 pax	Bot membuat passenger placeholder dan boleh mengumpulkan nama jamaah satu per satu jika user bersedia.
6-10 pax	Bot hanya kumpulkan data pemesan, jumlah pax, paket, dan catatan rombongan. Passenger detail diserahkan ke admin.
>10 pax	Trigger handover grup/rombongan. Bot tidak menjalankan slot filling passenger detail.
Unknown pax	Bot tanya jumlah pax terlebih dahulu sebelum membuat invoice.

Default Limit

MAX_BOT_PASSENGER_COLLECTION=5 dan MAX_BOT_BOOKING_PAX=10 di system_config. Nilai boleh diubah per client, tetapi default ini dipakai untuk menjaga flow tetap manusiawi dan tidak berubah jadi sensus penduduk mini.

14. RAG System Specification

RAG digunakan agar AI menjawab berdasarkan data resmi travel. AI tidak boleh menjawab paket dengan ingatan model umum. Model boleh pintar, tapi kalau tidak diberi data travel, ia hanya menebak dengan percaya diri. Itulah cara elegan menuju kekacauan mahal.

14.1 RAG Pipeline

- User question
 - > query normalization
 - > intent detection
 - > candidate package filtering
 - > structured retrieval from PostgreSQL
 - > vector retrieval from pgvector
 - > source ranking
 - > context builder
 - > answer generation
 - > safety guard validation
 - > send response
 - > save retrieval metadata

14.2 Vector Store Decision

Keputusan Production

Gunakan PostgreSQL + pgvector sebagai vector store utama. Alasannya: satu database untuk relational data dan vector search, lebih sederhana untuk multi-client B2B agency, lebih mudah backup, dan tidak menambah infrastruktur Qdrant/ChromaDB sejak awal.

Option	Status	Alasan
PostgreSQL + pgvector	Dipilih	Cocok untuk production single-instance multi-client, relational + vector dalam satu DB.
Qdrant	Tidak dipilih awal	Bagus untuk scale besar, tapi menambah infrastruktur. Bisa disiapkan adapter nanti.
ChromaDB	Tidak dipilih production	Cocok prototype/local, kurang ideal sebagai basis production multi-client.

14.3 Embedding & Chunking Strategy

Jenis Data	Chunking	Metadata Wajib
Package	1 package = 1 structured record + 1 searchable chunk	client_id, package_id, status, departure_month, price_version
Itinerary	Per hari atau per 300-500 token	client_id, package_id, day_number, doc_version
FAQ	1 question-answer = 1 chunk	client_id, category, doc_version
Terms	Per topik: DP, refund, pelunasan, dokumen	client_id, topic, effective_date, doc_version
Objection Handling	Per objection + answer	client_id, category, audience_type, doc_version

Jenis Data	Chunking	Metadata Wajib
Brand Voice	Tidak untuk fakta paket; dipakai sebagai style context	client_id, voice_version

Parameter	Default Production
Embedding model	text-embedding-3-small atau bge-m3 via provider yang dipilih di ai_config.
Chunk size naratif	300-500 token.
Chunk overlap	50-80 token untuk dokumen panjang.
Top K retrieval	5 untuk FAQ/terms, 3 untuk package-specific context.
Minimum retrieval score	0.55 untuk fallback terbatas, 0.75 untuk confident answer.
Reranking	Gunakan simple score + exact package/month filter. Cross-encoder bisa ditambahkan lewat adapter.
Source metadata logging	Simpan source_id, score, doc_version untuk setiap jawaban.

14.4 Retrieval Source

Source	Format	Keterangan
Packages	Database + JSON import	Data harga, tanggal, durasi, quota, fasilitas.
Itinerary	Markdown/Database	Rundown hari per hari.
Hotels	Database	Hotel Makkah, Madinah, jarak, rating, malam.
Airlines	Database	Maskapai, rute, bagasi, transit.
FAQ	Markdown/Database	Pertanyaan umum dan jawaban resmi.
Terms	Markdown/Database	DP, pelunasan, refund, dokumen.
Objection Handling	Markdown/Database	Jawaban untuk keberatan umum calon jamaah.
Bank Account	Config only	Tidak bebas di-RAG-kan. Hanya dari payment_config resmi.

14.5 Anti-Hallucination Rule

Data	Aturan
Harga	Wajib dari database package.
Tanggal	Wajib dari database departure.
Hotel	Wajib dari package_hotels.
Maskapai	Wajib dari package_airlines.
Rekening	Wajib dari client payment config versi aktif.
Kuota	Jika data tidak ada, jangan sebut angka.
Promo	Hanya boleh disebut jika active promo tersedia.
Payment status	Hanya admin manusia yang boleh mengubah menjadi paid.

15. Knowledge Base System

15.1 Knowledge Base Structure

```

clients/
{client_id}/
  config/
    client_config.json
    channel_config.json
    payment_config.json
    ai_config.json
    feature_flags.json
  knowledge/
    packages.json
    departures.json
    hotels.json
    airlines.json
    itinerary.md
    faq.md
    terms.md
    objection_handling.md

```

```
brand_voice.md
storage/
invoices/
uploads/
exports/
logs/
```

15.2 Package Schema

```
{
  "package_id": "UMR-OCT-12D",
  "package_code": "OCT12D",
  "package_name": "Umroh Oktober 12 Hari",
  "duration_days": 12,
  "departure_date": "2026-10-15",
  "return_date": "2026-10-26",
  "price_per_pax": 29000000,
  "currency": "IDR",
  "quota": 45,
  "remaining_seat": 12,
  "status": "active",
  "down_payment": 5000000,
  "airline_id": "SV-001",
  "hotel_ids": ["HTL-MK-001", "HTL-MD-001"],
  "included_facilities": [],
  "excluded_facilities": [],
  "price_version": "2026-07-v1"
}
```

15.3 Knowledge Update Rule

- Setiap update knowledge base harus memiliki version number.
- Sistem menyimpan last_updated_at dan updated_by.
- Bot tidak boleh memakai dokumen yang statusnya archived.
- Jika dua data konflik, sistem memilih data dengan priority tertinggi atau meminta admin.
- Bank account tidak boleh diambil dari FAQ bebas; wajib dari payment_config.
- Setiap jawaban RAG menyimpan doc_version yang dipakai agar bisa diaudit.

15.4 Knowledge Base Conflict Resolution

Jika ada dua data yang saling bertentangan, sistem tidak boleh memilih sembarangan. Conflict resolution memakai urutan deterministik agar jawaban bisa diaudit.

Priority Order	Rule
1	Gunakan document dengan is_active=true dan effective_from <= now <= effective_until jika effective_until ada.
2	Pilih source_type dengan prioritas tertinggi: package_database > admin_override > price_sheet > brochure_pdf > faq > old_chat_import.
3	Pilih doc_priority tertinggi jika disediakan secara eksplisit. Range 1-100, semakin besar semakin kuat.
4	Pilih doc_version terbaru jika source_type sama. Format semver atau integer revision.
5	Pilih updated_at terbaru jika version sama.
6	Jika konflik menyangkut harga, tanggal, rekening, kuota, atau terms dan tidak bisa diputuskan, bot wajib fallback ke admin.

```
knowledge_conflict_policy = {
  "source_priority": [
    "package_database",
    "admin_override",
    "price_sheet",
    "brochure_pdf",
    "faq",
    "old_chat_import"
  ],
  "fallback_to_admin_fields": ["price", "departure_date", "bank_account", "remaining_seat", "terms"],
}
```

```
"require_active_effective_date": true
}
```

16. Brand Voice Specification

brand_voice.md menentukan rasa bicara bot. Tanpa file ini, bot akan terdengar seperti customer service generik yang baru belajar sopan dari template internet. Untuk travel umroh, tone harus ramah, islami, menenangkan, dan tidak agresif menjual.

16.1 brand_voice.md Schema

Brand Voice - Travel Umroh Al-Falah

Core Tone

- Ramah
- Islami
- Tenang
- Jelas
- Tidak memaksa
- Tidak lebay

Panggilan User

Default: Ayah/Bunda

Alternatif: Bapak/Ibu, Ummi/Abi

Jangan memakai: kak, sis, bro, gan

Opening Style

Gunakan salam jika relevan.

Jawaban awal boleh memakai "Walaikumsalam Ayah/Bunda" jika user memberi salam.

Sentence Style

- Kalimat pendek sampai sedang.
- Jangan terlalu formal seperti surat kantor.
- Jangan terlalu puitis.
- Jangan memakai tekanan jualan berlebihan.

Approved Phrases

- "InsyaAllah saya bantu cekkan ya Ayah/Bunda."
- "Untuk data yang paling aman, saya bantu arahkan ke admin ya."
- "Pembayaran akan dicek manual oleh admin melalui mutasi rekening resmi."

Forbidden Phrases

- "Dijamin berangkat tanpa kendala."
- "Pembayaran sudah pasti masuk."
- "Seat pasti aman sebelum pembayaran/admin validasi."
- "Transfer saja ke rekening admin."

Example Answer

User: Hotelnya dekat Haram?

Bot: Untuk paket ini, hotel Makkah tercatat sekitar 300 meter dari Masjidil Haram ya Ayah/Bunda. Jadi insyaAllah masih cukup nyaman untuk akses ibadah.

16.2 Brand Voice Enforcement

- brand_voice.md dipakai sebagai style context, bukan sumber fakta paket.
- Jika brand voice bertentangan dengan safety rule, safety rule menang.
- Default user call dari client_config dapat menimpa brand_voice jika perlu.
- Response generator harus memasukkan brand_voice_version ke log.

17. Configuration System

Sistem harus bisa berubah perilaku lewat konfigurasi. Tujuannya jelas: nanti saat mau pindah Starsender ke WABA, dev tidak perlu menggali source code seperti arkeolog startup.

17.1 client_config.json

```
{
  "client_id": "travel_alfalah",
  "brand_name": "Travel Umroh Al-Falah",
  "bot_name": "Admin AI Al-Falah",
  "default_user_call": "Ayah/Bunda",
  "tone": "ramah, islami, tenang, jelas, tidak memaksa",
  "timezone": "Asia/Jakarta",
  "default_language": "id",
  "bot_enabled_default": true,
  "max_memory_turns": 5,
  "admin_group_id": "-100123456789"
}
```

17.2 channel_config.json

```
{
  "active_channel": "starsender",
  "channels": {
    "starsender": {
      "enabled": true,
      "api_key_env": "STARSENDER_API_KEY",
      "webhook_secret_env": "STARSENDER_WEBHOOK_SECRET"
    },
    "waba": {
      "enabled": false,
      "provider": "meta_cloud_api",
      "access_token_env": "WABA_ACCESS_TOKEN",
      "phone_number_id_env": "WABA_PHONE_NUMBER_ID",
      "verify_token_env": "WABA_VERIFY_TOKEN"
    }
  }
}
```

17.3 feature_flags.json

```
{
  "ai_autoreply": true,
  "rag_answering": true,
  "booking_collection": true,
  "passenger_collection": true,
  "invoice_generation": true,
  "manual_payment_verification": true,
  "payment_gateway": false,
  "admin_takeover": true,
  "followup_scheduler": true,
  "broadcast_segment": false,
  "waba_channel": false,
  "starsender_channel": true,
  "rate_limiting": true,
  "summary_generation": true
}
```

17.4 ai_config.json

Provider Decision

Gunakan OpenAI-compatible provider melalui satu LLM client wrapper. Default production disarankan provider yang punya SLA stabil. OpenRouter boleh dipakai jika cost menjadi prioritas, tetapi data privacy, latency, dan reliability harus dicatat per client.

Model String Validation

Nilai chat_model, intent_model, summary_model, fallback_model, dan embedding_model wajib divalidasi ke provider sebelum deploy.

Jalankan startup validation dengan test request ringan. Jika provider menolak model string, service tidak boleh start dalam mode production.

```
{
  "provider": "openai_compatible",
  "base_url": "https://api.openai.com/v1",
  "api_key_env": "LLM_API_KEY",
  "chat_model": "gpt-4o-mini",
  "embedding_model": "text-embedding-3-small",
  "temperature": 0.25,
  "max_output_tokens": 650,
  "intent_model": "gpt-4o-mini",
  "summary_model": "gpt-4o-mini",
  "fallback_model": "gpt-4o-mini",
  "timeout_seconds": 25,
  "max_retries": 2,
  "privacy_mode": {
    "send_full_chat_history": false,
    "max_memory_turns": 5,
    "redact_sensitive_documents": true
  },
  "safety": {
    "intent_confidence_min": 0.70,
    "retrieval_score_min": 0.55,
    "retrieval_score_confident": 0.75,
    "block_payment_confirmation": true,
    "block_unknown_bank_account": true
  }
}
```

17.5 payment_config.json

```
{
  "manual_payment_only": true,
  "auto_payment_confirmation": false,
  "active_bank_account_version": "bank-v2026-07-01",
  "bank_accounts": [
    {
      "bank_account_id": "bsi-main-001",
      "version": "bank-v2026-07-01",
      "bank_name": "Bank Syariah Indonesia",
      "account_number": "1234567890",
      "account_holder": "PT Travel Umroh Al-Falah",
      "is_active": true,
      "effective_from": "2026-07-01",
      "effective_until": null
    }
  ],
  "payment_instruction": "Transfer sesuai nominal invoice, lalu kirim bukti transfer untuk dicek admin.",
  "verification_message": "Pembayaran akan diverifikasi manual oleh admin melalui mutasi rekening resmi."
}
```

18. Follow-Up System

Follow-up bukan chat spam. Follow-up adalah task terjadwal yang dibuat ketika lead belum menyelesaikan langkah penting: belum pilih paket, belum isi data, belum bayar invoice, atau admin perlu menghubungi ulang.

18.1 Follow-Up Trigger

Trigger	Delay Default	Template Type	Stop Rule
Lead bertanya tapi tidak balas	6 jam	soft_checkin	User balas atau admin close.
User minat paket tapi belum booking	12 jam	package_reminder	User booking/admin close.

Trigger	Delay Default	Template Type	Stop Rule
Booking data belum lengkap	3 jam	data_completion	Data lengkap/admin takeover.
Invoice sent tapi belum ada bukti	8 jam	payment_reminder	Evidence received/admin cancel.
Payment evidence belum dicek admin	30 menit	admin_escalation	Admin update status.

18.2 Max Attempt Rule

Follow-Up Type	Max Attempt	Cooldown
soft_checkin	2 kali	Minimal 6 jam antar pesan.
package_reminder	2 kali	Minimal 12 jam antar pesan.
data_completion	3 kali	Minimal 3 jam antar pesan.
payment_reminder	2 kali	Minimal 8 jam antar pesan.
admin_escalation	Berulang sampai admin action	30 menit, lalu 2 jam jika sudah 3 kali.

18.3 Follow-Up Task Schema

```
{
  "followup_task_id": "fu_001",
  "client_id": "travel_alfalah",
  "contact_id": "ct_001",
  "conversation_id": "conv_001",
  "type": "payment_reminder",
  "scheduled_at": "2026-07-30T22:00:00+07:00",
  "attempt": 1,
  "max_attempt": 2,
  "status": "scheduled|sent|cancelled|failed|skipped",
  "cancel_if_stage_in": ["payment_evidence_received", "paid", "closed"],
  "created_by": "system"
}
```

19. Conversation Summary System

conversation_summary dipakai untuk admin handover, lead review, dan audit. Summary tidak boleh dibuat asal-asalan karena admin akan mengambil keputusan dari sana. Ringkasan harus pendek, faktual, dan menyebut hal yang masih perlu dilakukan.

19.1 Summary Trigger

Trigger	Action
Setiap 10 pesan baru	Refresh summary.
Sebelum handover admin	Generate summary wajib.
Sebelum follow-up besar	Refresh summary agar konteks tidak basi.
Saat booking dibuat	Simpan booking summary.
Saat invoice dikirim	Update summary dengan invoice dan nominal.

19.2 Summary Prompt

Tugas: Buat ringkasan percakapan untuk admin travel.

Aturan:

- Ringkas, faktual, maksimal 6 bullet.
- Jangan menambah fakta yang tidak ada di chat.
- Sebutkan nama, nomor, paket minat, jumlah pax, status invoice/payment jika ada.
- Sebutkan pertanyaan atau kebutuhan yang belum selesai.
- Jangan menyimpulkan pembayaran valid.

Output:

```
{
  "summary": "...",
  "open_questions": [],
  "lead_stage": "...",
  "next_admin_action": "..."
}
```

}

19.3 Summary Storage Rule

- Summary terbaru disimpan di conversations.summary.
- Versi historis dapat disimpan di conversation_summaries jika audit detail dibutuhkan.
- Summary harus menyimpan generated_by_model, generated_at, dan message_range.
- Summary tidak boleh dipakai sebagai sumber fakta invoice/payment; tetap baca tabel invoice/payment.

20. Functional Requirements

ID	Fitur	Requirement
FR-01	AI Customer Service	Menjawab chat calon jamaah dengan bahasa ramah islami berdasarkan context.
FR-02	RAG Answering	Mencari data dari knowledge base dan menjawab tanpa halusinasi.
FR-03	Intent Detection	Mendeteksi intent seperti ask_package, ask_price, booking_intent, payment_evidence, human_request.
FR-04	Entity Extraction	Mengambil nama, nomor HP, paket, jumlah pax, jadwal minat, kota asal.
FR-05	Database Capture	Menyimpan contact, lead profile, message, intent, booking, invoice, dan evidence.
FR-06	Lead Tagging	Memberi tag otomatis seperti hot_lead, ask_price, family_trip, needs_admin.
FR-07	Booking Collection	Mengumpulkan data booking sampai lengkap sebelum invoice dibuat.
FR-08	Passenger Collection	Membuat passenger placeholder per pax dan mengumpulkan nama jamaah jika user siap.
FR-09	Invoice Generator	Membuat PDF invoice dari data backend.
FR-10	Manual Payment Evidence	Menerima bukti transfer dan menyerahkan ke admin.
FR-11	Conversation Lock	Mengunci bot saat handover atau payment evidence masuk.
FR-12	Admin Notification	Mengirim alert ke grup/admin saat butuh intervensi manusia.
FR-13	Channel Adapter	Mendukung Starsender sekarang dan WABA siap konfigurasi.
FR-14	Follow-up System	Menjadwalkan reminder untuk leads berdasarkan status.
FR-15	Summary Generator	Membuat ringkasan percakapan untuk handover dan admin review.
FR-16	Rate Limiting	Melindungi sistem dari spam, flood, dan abuse.
FR-17	Audit Logging	Menyimpan semua event penting untuk debug dan laporan.

21. Invoice PDF Specification

Invoice harus terlihat resmi, mudah dibaca, dan konsisten. Developer tidak boleh membuat invoice seperti struk warung yang kebetulan bisa jadi PDF.

21.1 Visual Layout

[HEADER]

Logo kiri atas, nama travel, alamat/kontak resmi, nomor izin jika tersedia.

[TITLE]

INVOICE PEMESANAN UMROH

Invoice No, Booking ID, tanggal invoice, due date.

[CUSTOMER]

Nama pemesan, nomor WhatsApp, jumlah pax.

[PACKAGE DETAIL]

Nama paket, kode paket, tanggal berangkat, durasi, maskapai, hotel Makkah, hotel Madinah.

[COST BREAKDOWN]

Harga per pax, jumlah pax, subtotal, diskon jika ada, total invoice.

[PAYMENT INSTRUCTION]
Bank, nomor rekening, atas nama, catatan transfer, manual verification disclaimer.

[FOOTER]
Disclaimer: invoice bukan bukti lunas. Pembayaran sah setelah admin cek mutasi.

21.2 Invoice Required Fields

Field	Source of Truth
invoice_number	InvoiceService generated sequence.
booking_id	bookings table.
client brand/logo	clients + client_config.
customer_name	bookings/customer.
customer_phone	contacts/bookings.
package_name	packages table.
departure_date	departures table.
pax	bookings.pax.
price_per_pax	packages price_version active at invoice time.
total_amount	backend calculation.
bank account	payment_config active version.
payment disclaimer	static approved legal text.

21.3 Invoice Number Format

INV-{CLIENT_CODE}-{YYYYMMDD}-{RUNNING_NUMBER}
Example: INV-ALFALAH-20260730-0001

- Rules:
- Running number reset daily per client.
 - Invoice number immutable after PDF generated.
 - Invoice stores bank_account_version and package_price_version.
 - If invoice must be revised, create a new invoice revision. Do not overwrite the old PDF.

22. Payment Manual System

Payment di sistem ini harus manual. Sistem boleh membuat invoice, mengirim instruksi pembayaran, menerima bukti transfer, dan memberi tahu admin. Sistem tidak boleh mengesahkan pembayaran otomatis.

22.1 Payment Flow

- Invoice dikirim ke user
- > user transfer manual ke rekening resmi
 - > user kirim bukti transfer
 - > sistem melakukan evidence triage
 - > sistem simpan file evidence
 - > bot kirim acknowledgement tanpa validasi
 - > conversation lock
 - > admin notification
 - > admin cek mutasi bank secara manual
 - > admin update payment_status

22.2 Payment Status

Status	Siapa yang Mengubah	Makna
unpaid	System	Invoice belum dibayar.
evidence_received	System	Bukti transfer diterima, belum valid.
manual_checking	Admin	Admin sedang cek mutasi.
paid	Admin only	Pembayaran valid setelah cek manual.
invalid	Admin only	Bukti tidak cocok atau belum masuk mutasi.
cancelled	Admin only	Invoice dibatalkan.
expired	System/Admin	Invoice melewati due date dan perlu tindakan admin.

22.3 Forbidden Payment Behavior

- Bot tidak boleh berkata "pembayaran berhasil".
- Bot tidak boleh berkata "sudah lunas".
- Bot tidak boleh mengubah status paid.
- Bot tidak boleh menyimpulkan valid dari gambar resi.
- Bot tidak boleh membaca nominal resi lalu mencocokkan sebagai validasi final.
- Bot hanya boleh berkata bukti diterima dan akan dicek admin.

22.4 Payment Evidence Triage

Condition	Action
Conversation status = waiting_payment_evidence + user kirim image/file	Treat as likely payment evidence, save file, lock, notify admin.
User kirim image/file tapi belum ada invoice	Jangan lock otomatis. Tanya konteks file atau handover soft ke admin.
Caption mengandung bukti/transfer/resi/tf/sudah bayar	Treat as likely payment evidence.
File jelas bukan payment evidence berdasarkan caption user	Simpan sebagai attachment biasa dan minta klarifikasi.
Multiple files dikirim	Simpan semua, gabungkan dalam satu evidence batch.

22.5 Evidence Timeout & Escalation

Timeout	Action
30 menit tanpa admin action	Kirim ulang notifikasi admin dengan label escalation_1.
2 jam tanpa admin action	Kirim notifikasi ke owner/lead admin jika tersedia.
6 jam tanpa admin action	Bot boleh kirim update aman ke user: bukti sudah diteruskan, admin masih cek. Tidak menyebut valid/lunas.
24 jam tanpa admin action	Mark as admin_overdue dan tampilkan di dashboard/ops report.

22.6 Bank Account Versioning

- Setiap rekening memiliki bank_account_id, version, effective_from, effective_until, is_active.
- Invoice menyimpan bank_account_version yang dipakai saat invoice dibuat.
- Rekening lama tidak boleh dihapus jika sudah pernah dipakai invoice. Ubah menjadi inactive/expired.
- Jika rekening berubah, invoice lama tetap menampilkan rekening versi lama dan admin wajib tahu.
- Perubahan rekening wajib tercatat di audit_logs dengan admin_id/operator_id.

22.7 Cancellation Flow

Admin memilih cancel invoice/booking
-> wajib isi cancellation_reason
-> invoice.payment_status = cancelled
-> booking.status = cancelled atau partially_cancelled
-> follow-up terkait payment dibatalkan
-> user boleh dikirim pesan manual oleh admin
-> audit_logs mencatat admin_id, timestamp, reason

Bot tidak boleh membatalkan invoice atas inisiatif sendiri.

22.8 Invoice Expiry Automation

Status expired harus dipicu oleh worker/cron, bukan dibiarkan menjadi tebakan admin. Sistem memeriksa due_at invoice secara periodik dan menandai invoice yang melewati batas.

Rule	Specification
Cron schedule	Setiap 15 menit: scan invoice unpaid/evidence_received/manual_checking yang due_at sudah lewat.
Grace window	Default 2 jam setelah due_at sebelum status menjadi expired. Config: payment.expiry_grace_minutes.
Eligible status	unpaid saja otomatis expired. evidence_received dan manual_checking masuk admin_overdue, bukan expired otomatis.
User message	Bot tidak otomatis menyalahkan user. Jika follow-up aktif, kirim pesan aman sesuai template expired_unpaid.
Admin notification	Kirim summary invoice expired ke admin setiap batch, bukan spam satu per satu jika banyak.
Reopen rule	Admin boleh membuat invoice revision baru jika user ingin lanjut setelah expired. Invoice lama tetap immutable.

23. Human Handover System

23.1 Trigger Handover

Trigger	Action
User kirim bukti pembayaran	Lock conversation, notify admin.
User minta admin/manusia	Notify admin dan hentikan auto-reply.
AI confidence rendah	Fallback ke admin.
Pertanyaan di luar knowledge base	Arahkan ke admin.
User komplain/marah	Admin takeover.
User kirim dokumen sensitif	Admin takeover.
System error	Notify admin internal.
Abuse/flood detected	Rate limit dan notify admin jika perlu.

23.2 Admin Notification Template

URGENT HANDOVER REQUIRED

Client: {client_name}

Reason: {reason}

Conversation ID: {conversation_id}

Nama: {contact_name}

Nomor WA: {phone}

Lead Stage: {lead_stage}

Paket Minat: {package_name}

Jumlah Pax: {pax}

Invoice: {invoice_number}

Total: {total_amount}

Ringkasan Chat:

{conversation_summary}

Action:

Admin cek mutasi manual dan ambil alih chat.

23.3 Conversation Status

Status	Bot Behavior
bot_active	Bot boleh menjawab otomatis.
collecting_data	Bot mengumpulkan field booking/passenger ringan.
waiting_payment_evidence	Bot boleh menjawab reminder, tetapi file/gambar memicu payment triage.
handover_required	Bot tidak menjawab otomatis, admin wajib masuk.
human_active	Bot diam, admin sedang menangani.
bot_paused_by_admin	Bot diam sampai admin mengaktifkan.
closed	Bot tidak follow-up kecuali dibuka ulang.

23.4 Return Control to Bot

Admin command/action:

/bot_on {conversation_id} {reason}

System behavior:

1. Validate admin permission.
2. Update conversation.status = bot_active.
3. Set bot_enabled = true.
4. Save audit log.
5. Refresh conversation_summary.
6. Bot may answer next user message.

Optional user message:

"Baik Ayah/Bunda, admin sudah membantu pengecekan. Jika ada pertanyaan lain tentang paket, saya siap bantu kembali ya."

24. Rate Limiting & Anti-Abuse

Sistem WhatsApp publik akan menerima spam, salah kirim, flood, bahkan bot lain. Tidak ada sistem produksi yang boleh berasumsi semua manusia datang dengan niat suci dan koneksi stabil.

Rule	Limit Default	Action
Per phone message burst	10 pesan / 60 detik	Masuk cooldown 5 menit.
Per phone daily	300 pesan / hari	Mute otomatis dan notify admin.
Per client webhook	100 request / menit	Throttle request dan log.
Repeated identical message	5 kali berturut-turut	Mark spam_suspected.
Large file upload	> 10 MB	Reject/skip processing, notify user/admin.
Unknown bot pattern	High frequency + no semantic response	abuse_limited.

24.1 Abuse State

State	Makna	Recovery
normal	Tidak ada abuse.	Normal.
cooldown	Terlalu banyak pesan singkat.	Auto recover setelah cooldown.
spam_suspected	Pola pesan mencurigakan.	Admin review atau auto recover 24 jam.
abuse_limited	Nomor dibatasi.	Admin manual unblock.

25. ERD & Data Model

25.1 Core Entity Relationship

CLIENTS

- > CHANNEL_ACCOUNTS
- > ADMIN_USERS
- > KNOWLEDGE_DOCUMENTS
- > PACKAGES
- > CONTACTS
- > BANK_ACCOUNTS

CONTACTS

- > LEADS
- > CONVERSATIONS
- > BOOKINGS

CONVERSATIONS

- > MESSAGES
- > INTENT_EVENTS
- > CONVERSATION_SUMMARIES
- > HANDOVER_EVENTS
- > FOLLOW_UP_TASKS

PACKAGES

- > DEPARTURES
- > PACKAGE_HOTELS
- > PACKAGE_AIRLINES
- > BOOKINGS

BOOKINGS

- > PASSENGERS
- > INVOICES

INVOICES

- > PAYMENT_EVIDENCES
- > PAYMENT_VERIFICATION_EVENTS

ADMIN_USERS

- > HANDOVER_EVENTS
- > PAYMENT_VERIFICATION_EVENTS
- > FOLLOW_UP_TASKS
- > AUDIT_LOGS

25.2 Entity Table

Entity	Fungsi
clients	Data setiap travel/client.
channel_accounts	Akun Starsender/WABA/Telegram milik client.
admin_users	Admin internal travel atau agency.
contacts	Orang/nomor WhatsApp yang masuk ke sistem.
leads	Profil prospek dan status funnel.
conversations	Thread percakapan per contact dan channel.
messages	Semua pesan masuk/keluar.
intent_events	Hasil deteksi intent dan entity AI.
conversation_summaries	Riwayat summary percakapan.
packages	Data paket umroh.
departures	Jadwal keberangkatan per paket.
package_hotels	Hotel dalam paket.
package_airlines	Maskapai dalam paket.
knowledge_documents	Dokumen RAG dan knowledge base.
knowledge_chunks	Chunk yang di-embed ke pgvector.
bookings	Draft booking dari percakapan.
passengers	Data jamaah per booking.
invoices	Invoice PDF dan nominal tagihan.
bank_accounts	Rekening payment dengan versioning.
payment_evidences	Bukti transfer/file dari user.
payment_verification_events	Riwayat verifikasi manual admin.
handover_events	Event perpindahan ke admin manusia.
follow_up_tasks	Reminder dan follow-up leads.
rate_limit_events	Event spam/flood/cooldown.
audit_logs	Log sistem untuk debug dan compliance.

25.3 Important Fields

Table	Fields Utama
contacts	id, client_id, name, phone, normalized_phone, source_channel, first_seen_at, last_seen_at
leads	id, client_id, contact_id, stage, interest_package_id, pax_estimate, budget_range, tags, score, assigned_admin_id
conversations	id, client_id, contact_id, channel_account_id, status, bot_enabled, assigned_admin_id, summary, last_message_at
messages	id, client_id, conversation_id, sender_type, message_type, content, file_path, raw_payload, created_at
intent_events	id, client_id, message_id, intent, confidence, entities_json, missing_fields_json
bookings	id, client_id, contact_id, package_id, customer_name, customer_phone, pax, total_amount, status
passengers	id, client_id, booking_id, full_name, passenger_index, data_status, notes
invoices	id, client_id, booking_id, invoice_number, amount, pdf_path, payment_status, due_at, bank_account_version, price_version
payment_evidences	id, client_id, invoice_id, file_path, caption, status, uploaded_at

26. File System & Repository Structure

```

ai-cs-travel-umroh/
  app/
    main.py
    config.py
    bootstrap.py

  channels/
    base_adapter.py
    starsender_adapter.py
    waba_adapter.py
    telegram_adapter.py
    web_widget_adapter.py

```


ingestion/
message_normalizer.py
contact_resolver.py
event_handler.py
rate_limiter.py
idempotency.py

conversation/
orchestrator.py
state_manager.py
memory_manager.py
lock_manager.py
summary_service.py

ai/
llm_client.py
prompt_builder.py
intent_detector.py
entity_extractor.py
response_generator.py
safety_guard.py

rag/
knowledge_loader.py
chunker.py
embedder.py
retriever.py
vector_store_pgvector.py
source_ranker.py

business/
lead_service.py
booking_service.py
passenger_service.py
invoice_service.py
payment_evidence_service.py
handover_service.py
followup_service.py

admin/
notification_service.py
admin_command_service.py
takeover_service.py

workers/
queue.py
jobs_invoice.py
jobs_notification.py
jobs_followup.py
jobs_summary.py
dead_letter.py

storage/
database.py
repositories/
migrations/

utils/
logger.py
validators.py
phone_normalizer.py
currency_formatter.py

```

clients/
{client_id}/
  config/
  knowledge/
  storage/
    invoices/
    uploads/
  exports/
  logs/

docker/
Dockerfile
docker-compose.yml
nginx.conf

tests/
test_channel_adapter.py
test_database_capture.py
test_rag.py
test_booking.py
test_invoice.py
test_payment_manual.py
test_handover.py
test_rate_limit.py

.env.example
requirements.txt
README.md

```

27. API & Internal Service Contract

27.1 Core Service Contract

Service	Input	Output
MessageIngestionService	Raw provider payload	Normalized MessageEvent
ContactResolver	Phone, client_id	Contact + Lead Profile
RateLimiter	MessageEvent	allowed/limited decision
ConversationOrchestrator	MessageEvent	Next action
IntentDetector	Text + context	Intent JSON
RAGRetriever	Query + client_id	Relevant context
ResponseGenerator	Prompt + context	Natural answer
SafetyGuard	AI response + metadata	safe/block/fallback decision
LeadService	Contact + intent	Updated lead profile
BookingService	Entities + package	Booking draft
PassengerService	Booking + pax	Passenger records/placeholders
InvoiceService	Booking id	Invoice PDF
PaymentEvidenceService	File message	Evidence record + handover trigger
HandoverService	Conversation + reason	Locked conversation + admin alert
FollowupService	Lead/conversation state	Scheduled follow-up task

27.2 Intent JSON Contract

```

{
  "intent": "booking_intent",
  "confidence": 0.92,
  "entities": {
    "package_id": "UMR-OCT-12D",
    "package_name": "Umroh Oktober 12 Hari",
    "pax": 2,
    "customer_name": "Muhammad Firdaus",
    "customer_phone": "628123456789",
    "departure_month": "Oktober"
  },
  "missing_fields": [],

```

```
"should_handover": false,
"safety_state": "safe_response"
}
```

28. Queue & Worker Specification

Queue diperlukan agar notifikasi, invoice, summary, dan follow-up tidak bergantung pada satu request webhook. Kalau semua dikerjakan sinkron di webhook, satu timeout kecil bisa membuat sistem tampak seperti pingsan.

28.1 Queue Decision

Keputusan Production

Gunakan Redis + RQ/Celery jika backend Python. Jika backend Node/NestJS, gunakan BullMQ. Pilih satu sesuai stack utama. Untuk dokumen ini, asumsi default adalah Python FastAPI + Celery + Redis.

Queue	Job	Retry Rule	Dead Letter
invoice_queue	Generate PDF invoice dan simpan file.	3 retry, exponential backoff.	invoice_failed_jobs
notification_queue	Kirim notifikasi admin/user.	5 retry, backoff 30s, 2m, 10m.	notification_failed_jobs
followup_queue	Kirim/schedule follow-up.	3 retry.	followup_failed_jobs
summary_queue	Generate conversation summary.	2 retry.	summary_failed_jobs
rag_index_queue	Index/update knowledge chunks.	3 retry.	rag_failed_jobs

28.2 Worker Safety Rules

- Setiap job harus idempotent menggunakan job_key unik.
- Failed job tidak boleh hilang; masuk dead-letter table/queue.
- Admin notification untuk payment evidence harus prioritas tinggi.
- Follow-up job harus cek stage terbaru sebelum kirim agar tidak mengganggu user yang sudah closing.
- Invoice job tidak boleh regenerate invoice lama tanpa revision record.

29. Multi-Client Isolation

Produk agency B2B harus aman untuk banyak travel. Data travel A tidak boleh nyasar ke travel B. Itu bukan bug kecil, itu bencana reputasi dengan logo yang berbeda.

29.1 Isolation Decision

Layer	Isolation Rule
Database	Semua tabel wajib punya client_id, kecuali global config tertentu. Row-level filter wajib di repository layer.
Vector Store	Semua chunk memiliki client_id dan retrieval wajib filter client_id.
Storage	File path wajib clients/{client_id}/storage/...
Webhook	Route/payload wajib memetakan channel_account_id ke client_id.
Config	Config per client, tidak boleh global hardcoded.
Admin Access	Admin hanya bisa melihat client yang assigned. Agency superadmin bisa multi-client.

29.2 Database Strategy

Keputusan Awal

Gunakan satu PostgreSQL database multi-tenant dengan client_id di setiap tabel dan repository-level enforcement. Jangan memakai database terpisah per client di awal karena akan memperberat operasional agency. Namun desain migration harus memungkinkan split tenant nanti jika dibutuhkan.

30. Deployment Specification

Deployment harus jelas sejak awal. Sistem ini dijual sebagai produk B2B, bukan skrip lokal yang hidup hanya di laptop developer yang namanya tidak boleh disebut.

30.1 Deployment Model

Komponen	Rekomendasi
Application	Docker container: FastAPI/NestJS app.
Database	PostgreSQL + pgvector. Bisa managed atau container terpisah.
Queue	Redis container + worker container.
Reverse Proxy	Nginx/Caddy dengan HTTPS.
Storage	Local mounted volume awal; S3-compatible untuk scale.
Process	docker compose untuk awal, bisa naik ke VPS production.
Environment	.env per deployment, config per client di DB/file.
Backup	Daily PostgreSQL backup + weekly file storage backup.

30.2 Single Instance Multi-Client

- Satu backend instance melayani banyak client.
- Setiap request wajib resolve client_id dari channel_account_id atau route key.
- Worker job wajib membawa client_id.
- Webhook endpoint dapat memakai /webhooks/{channel}/{channel_account_id}.
- Admin dashboard/API wajib enforce permission per client.

30.3 Environment Required

```
APP_ENV=production
APP_URL=https://ai-cs.example.com
DATABASE_URL=postgresql://user:pass@postgres:5432/aics
REDIS_URL=redis://redis:6379/0
STORAGE_ROOT=/app/storage
LLM_API_KEY=xxx
STARSENTER_API_KEY=xxx
WABA_ACCESS_TOKEN=xxx
TELEGRAM_BOT_TOKEN=xxx
ADMIN_DEFAULT_GROUP_ID=-100123456789
```

31. Security, Privacy & Compliance

- API key dan token disimpan di environment variable, bukan di repository.
- Raw webhook payload disimpan untuk audit, tetapi aksesnya dibatasi.
- Data calon jamaah disimpan per client dan tidak boleh tercampur.
- Payment evidence tidak boleh diproses sebagai validasi otomatis.
- Dokumen sensitif seperti KTP dan paspor tidak diminta oleh AI secara bebas.
- Admin action seperti paid/invalid/cancelled harus tercatat dengan admin_id dan timestamp.
- Semua outgoing message yang mengandung harga, rekening, atau invoice harus tervalidasi dari backend.
- LLM request tidak mengirim seluruh histori chat; gunakan sliding memory dan summary.

32. Logging & Monitoring

Event	Wajib Disimpan
message_received	client_id, conversation_id, contact_id, channel, message_type, timestamp
message_sent	conversation_id, channel, content_hash, status
intent_detected	message_id, intent, confidence, entities
rag_retrieved	query, source_ids, score, client_id, doc_version
safety_guard_blocked	reason, original_response_hash, fallback_used
lead_updated	lead_id, old_stage, new_stage, tags
booking_created	booking_id, contact_id, package_id, pax, total
passenger_updated	booking_id, passenger_id, old_status, new_status
invoice_generated	invoice_id, invoice_number, pdf_path, amount
payment_evidence_received	invoice_id, file_path, status
payment_timeout_escalated	invoice_id, escalation_level, admin_target
handover_triggered	conversation_id, reason, admin_group
admin_payment_update	invoice_id, admin_id, old_status, new_status
rate_limit_triggered	contact_id, rule, limit, action
system_error	error_type, stack_trace, affected_service

33. Admin Operation SOP

33.1 SOP Chat Masuk

1. Sistem menerima chat dari WhatsApp dan menyimpan contact.
2. AI menjawab pertanyaan dasar jika bot aktif.
3. Lead profile otomatis diperbarui berdasarkan intent.
4. Jika user panas atau ingin booking, sistem mengumpulkan data.
5. Jika butuh admin, sistem kirim notifikasi takeover.

33.2 SOP Payment Manual

1. User menerima invoice PDF dari sistem.
2. User transfer ke rekening resmi.
3. User kirim bukti transfer ke WhatsApp.
4. Sistem melakukan evidence triage, menyimpan bukti, dan mengunci bot.
5. Admin menerima notifikasi urgent.
6. Admin cek mutasi bank secara manual.
7. Admin update status invoice menjadi paid, pending/manual_checking, invalid, expired, atau cancelled.
8. Admin menghubungi user dan melanjutkan proses administrasi.
9. Admin mengembalikan bot jika percakapan sudah aman untuk otomatisasi.

33.3 SOP Update Knowledge Base

1. Agency/admin membuka file atau dashboard knowledge base.
2. Update paket, harga, jadwal, hotel, maskapai, FAQ, terms, atau brand voice.
3. Jalankan validasi schema.
4. Simpan version number baru.
5. Jalankan indexing ulang ke pgvector.
6. Test minimal pertanyaan harga, jadwal, hotel, DP, dan fallback data kosong.
7. Aktifkan knowledge version terbaru.

34. Testing Scenario

34.1 Core Test

Scenario	Expected Result
User tanya paket Oktober	Bot mengambil data paket Oktober dari knowledge base.
User tanya hotel	Bot menjawab hotel sesuai package_id.
User tanya harga 2 pax	Backend menghitung total, AI menyampaikan hasil.
User ingin booking	Bot mengumpulkan nama, nomor HP, paket, pax.
User booking 3 pax	Sistem membuat passenger placeholders dan bertanya data jamaah opsional.
Data lengkap	Backend membuat booking dan invoice PDF.
User kirim bukti transfer	Bot tidak validasi, lock conversation, notify admin.
Admin tidak action 30 menit	Sistem escalation notification.
Admin update paid	Status berubah dengan admin_id dan timestamp.
Admin return bot	Status kembali bot_active dan bot boleh menjawab pesan berikutnya.
Bot dimatikan admin	Pesan berikutnya hanya disimpan, tidak dijawab AI.
Pindah channel ke WABA	Core logic tetap sama, hanya config adapter berubah.

34.2 Negative Test

Case	Expected Safety Behavior
User tanya paket yang tidak ada	Bot tidak mengarang dan arahkan ke admin.
User kirim bukti tanpa invoice	Bot tanya konteks atau arahkan admin, tidak lock otomatis.
User minta konfirmasi lunas	Bot menolak konfirmasi dan arahkan ke admin.
Knowledge base kosong	Bot tidak aktif menjawab paket.
Provider Starsender error	Sistem menyimpan error dan membuat retry/log.
AI confidence rendah	Bot fallback ke admin.
Nomor spam kirim 20 pesan/menit	Rate limit aktif dan admin dapat log.
Rekening lama inactive	Invoice baru tidak boleh memakai rekening inactive.

35. Feature Activation Sequence

Semua modul disiapkan di backend dari awal. Namun aktivasi di production harus berurutan lewat `feature_flags` supaya testing lebih aman. Ini bukan pembagian produk bertahap, ini urutan menyalakan saklar agar tidak membakar rumah.

Urutan	Feature Flags	Tujuan Aktivasi
1	database_capture, starsender_channel, rate_limiting	Pastikan semua chat masuk tersimpan aman.
2	rag_answering, ai_autoreply, safety_guard	Aktifkan AI jawab informasi dengan kontrol safety.
3	booking_collection, passenger_collection	Aktifkan pengumpulan data booking dan pax.
4	invoice_generation, manual_payment_verification	Aktifkan invoice dan bukti pembayaran manual.
5	admin_takeover, summary_generation	Aktifkan handover lengkap dan summary admin.
6	followup_scheduler	Aktifkan follow-up setelah flow inti stabil.
7	waba_channel	Ganti channel aktif ke WABA saat credential dan webhook siap.
Locked	payment_gateway=false	Tetap nonaktif karena payment harus manual.

36. Developer Implementation Notes

Keputusan Teknis Utama

Gunakan arsitektur adapter dan service-layer. Jangan biarkan logic Starsender masuk ke booking, invoice, RAG, lead service, atau payment flow. Kalau itu terjadi, migrasi ke WABA nanti akan menjadi acara bedah jantung source code.

36.1 Recommended Stack

Layer	Recommendation
Backend	Python FastAPI atau Node.js/NestJS. Pilih salah satu dan konsisten. Default dokumen: Python FastAPI.
Database	PostgreSQL + pgvector untuk production. SQLite hanya untuk local development.
Queue	Redis + Celery/RQ untuk retry, invoice, notification, summary, dan follow-up.
RAG	PostgreSQL pgvector. Qdrant adapter bisa disiapkan nanti jika scale menuntut.
PDF	WeasyPrint HTML template atau FPDF2. Untuk layout rapi, WeasyPrint lebih disarankan.
Storage	Local mounted volume awal, S3-compatible untuk production lebih rapi.
AI Provider	OpenAI-compatible API via <code>ai_config</code> . Privacy dan latency dicatat per client.
Channel	Starsender aktif, WABA prepared adapter.
Deployment	Docker Compose di VPS production dengan HTTPS dan backup rutin.

36.2 Non-Negotiable Developer Rules

- Tidak boleh hardcode data client di source code.
- Tidak boleh hardcode Starsender di core service.
- Tidak boleh membuat payment gateway auto-paid.
- Tidak boleh membiarkan AI menghitung invoice final.
- Tidak boleh menyimpan chat hanya di WhatsApp.
- Tidak boleh menghapus raw payload webhook sebelum tersimpan.
- Tidak boleh mengubah source code hanya untuk menambah client baru.
- Tidak boleh membiarkan bot menjawab saat status conversation `handover_required` atau `human_active`.
- Tidak boleh retrieval vector tanpa filter `client_id`.
- Tidak boleh mengirim data dokumen sensitif ke LLM tanpa redaction/privacy rule.

36.3 Final Operating Definition

Sistem dianggap siap produksi jika semua chat WhatsApp yang masuk dapat ditangkap ke database, dijawab oleh AI berdasarkan knowledge base, dipetakan menjadi lead profile, diproses menjadi booking jika user berminat, dibuatkan invoice oleh backend, lalu pembayaran ditangani lewat bukti transfer dan verifikasi manual admin.

Sistem juga harus siap pindah channel dari Starsender ke WABA melalui konfigurasi adapter. Tidak perlu rewrite core source code. Yang berubah hanya channel config, token, webhook route, dan adapter aktif.

Inti desainnya sederhana: AI melayani percakapan, backend menjaga kebenaran data, database menyimpan semua leads, dan admin manusia tetap memegang keputusan pembayaran. Di tengah semesta software yang gemar meledak diam-diam, ini setidaknya cukup waras.

37. AI Agent Prompt Contract

Section ini adalah kontrak kerja untuk AI coding agent yang akan membaca PRD ini. Agent tidak boleh memilih urutan build sendiri berdasarkan selera. Selera agent biasanya berakhir dengan dashboard cantik tapi database belum ada, sebuah tragedi kecil yang terlalu sering terjadi.

37.1 Build Objective for Agent

- Bangun backend production-ready untuk AI CS travel umroh dengan Starsender aktif dan WABA-ready adapter.
- Pastikan semua chat masuk tersimpan ke database sebelum diproses AI.
- Pastikan semua keputusan transaksional berasal dari backend dan admin manusia, bukan LLM.
- Pastikan semua modul dapat diaktifkan/dimatikan lewat configuration dan feature flags.
- Pastikan semua tabel inti, migrations, service layer, queue, dan adapter interface tersedia dari awal.

37.2 Mandatory Build Order

Order	Module	Acceptance Check
1	Project skeleton + config loader	Service bisa boot dengan .env dan config per client.
2	Database schema + migrations	Semua tabel inti tersedia, termasuk client_id dan audit fields.
3	Channel adapter interface + Starsender adapter	Incoming webhook dinormalisasi ke MessageEvent.
4	Idempotency + message capture	Webhook duplicate tidak membuat pesan ganda.
5	Contact, lead, conversation state manager	Setiap nomor WA masuk menjadi contact + lead profile.
6	RAG ingestion + pgvector retrieval	Knowledge base bisa di-index dan di-retrieve dengan filter client_id.
7	LLM wrapper + ai_config validation	Startup memvalidasi model string dan test request ringan.
8	Intent/entity extraction + safety guard	Output AI melewati safety dan confidence threshold.
9	Booking + multi-pax rules	Booking 1-5 pax berjalan, >10 pax handover.
10	Invoice generation + immutable PDF	Invoice tersimpan dengan bank_account_version dan price_version.
11	Manual payment evidence + handover	Bukti transfer mengunci bot dan notifikasi admin.
12	Queue workers	Retry, follow-up, summary, invoice expiry, notification berjalan.
13	Admin commands/control	Admin bisa bot_off, bot_on, set human_active, mark paid/invalid/cancelled.
14	Testing + implementation checklist	Semua checklist modul lulus.

37.3 Output Format Expected From Agent

- Agent harus membuat struktur folder sesuai Section 26.
- Agent harus membuat migration SQL atau ORM migration sesuai DATABASE_SCHEMA.sql.
- Agent harus membuat README setup local dan production Docker.
- Agent harus membuat test minimal untuk idempotency, RAG retrieval, invoice, payment evidence, dan handover.
- Agent harus membuat sample client travel_alfalah dengan config dan knowledge base dummy.
- Agent harus menuliskan known limitations jika ada modul yang belum bisa berjalan karena credential belum tersedia.

37.4 Things Agent Must Not Assume

- Jangan mengasumsikan WABA sudah aktif. Starsender aktif sekarang, WABA disiapkan adapter-nya.
- Jangan mengasumsikan payment gateway akan dipakai. Payment harus manual.
- Jangan mengasumsikan semua client memakai tone yang sama. Gunakan brand_voice.md per client.
- Jangan mengasumsikan semua user booking 1 pax. Multi-pax harus ada limit dan handover rule.
- Jangan mengasumsikan satu database per client. Default adalah single database multi-tenant dengan client_id di semua tabel tenant-owned.
- Jangan mengasumsikan model AI pasti valid. Model string wajib divalidasi ke provider saat startup/deploy.

38. Definisi Eksplisit untuk Setiap Ambiguitas

Bagian ini mengunci interpretasi agar developer dan AI agent tidak membuat definisi sendiri. Kreativitas itu bagus untuk iklan, bukan untuk schema database.

Ambiguous Phrase	Explicit Definition
Simpan ke database	Insert ke tabel messages dengan fields id, client_id, conversation_id,

Ambiguous Phrase	Explicit Definition
	contact_id, direction, message_type, text_content, file_url, raw_payload_id, created_at. Gunakan repository dari storage/repositories.py dan transaction dari storage/database.py.
Webhook dobel jangan diproses ulang	Cek tabel webhook_idempotency_keys dengan unique(client_id, channel, idempotency_key). Jika sudah ada, increment duplicate_count, return OK, stop processing.
Bot aktif/nonaktif	Gunakan conversations.bot_enabled dan conversations.status. Jika bot_enabled=false atau status in handover_required/human_active/abuse_limited, bot tidak boleh auto-reply.
Manual payment	Admin manusia wajib mengubah payment_status ke paid/invalid/cancelled. LLM dan worker tidak boleh mengubah ke paid.
Generate summary	Worker membuat atau memperbaiki conversations.summary memakai summary_model dari ai_config setiap 10 pesan baru atau sebelum handover notification.
Knowledge terbaru	Gunakan conflict policy Section 15.4. Untuk harga/rekening/tanggal konflik, fallback ke admin.
Data passenger	Untuk <=5 pax, buat passenger placeholders dan kumpulkan nama jika user bersedia. Untuk >10 pax, handover ke admin.
Invoice expired	Worker scan setiap 15 menit. unpaid dengan now > due_at + expiry_grace_minutes berubah ke expired. evidence_received tidak auto-expired.
Health check gagal	Pause auto-reply channel terkait, simpan incoming, queue outgoing, dan notify ops/admin.
Client isolation	Semua query tenant-owned wajib filter client_id. Vector retrieval wajib filter client_id dan knowledge_version active.

38.1 Explicit File Ownership

File/Module	Responsibility
storage/database.py	Session factory, transaction context, DB connection.
storage/repositories.py	CRUD untuk clients, contacts, conversations, messages, bookings, invoices, payments.
channels/base.py	Abstract ChannelAdapter interface.
channels/starsender_adapter.py	Starsender payload parsing and sending. Tidak boleh memuat booking logic.
core/router.py	Routing MessageEvent ke service berdasarkan status dan intent.
core/state_manager.py	Conversation status transition dan bot_enabled.
rag/retriever.py	pgvector retrieval dengan client_id filter dan conflict policy.
ai/llm_client.py	Provider wrapper, model validation, retry, timeout.
ai/safety_guard.py	Forbidden output, confidence checks, data consistency checks.
booking/invoice_generator.py	PDF invoice immutable berdasarkan backend data.
payment/manual_payment_service.py	Evidence triage, lock, admin notification. Tidak boleh mark paid otomatis.
workers/tasks.py	Queue tasks: retry send, summary, follow-up, expiry, notification.

39. Constraint & Forbidden Patterns untuk Code Generation

Bagian ini wajib dibaca oleh AI agent sebelum generate code. Tujuannya mencegah pola coding yang kelihatan cepat, lalu membuat migrasi dan maintenance terasa seperti hukuman sosial.

39.1 Required Technical Constraints

- Default backend: Python FastAPI dengan SQLAlchemy/Alembic atau SQLModel. Jika stack diubah, seluruh module contract tetap wajib dipertahankan.
- Database production: PostgreSQL + pgvector. SQLite hanya untuk local smoke test, bukan production target.
- Queue production: Redis + Celery/RQ. Queue task wajib idempotent.
- Configuration menggunakan .env + client config file + database config. Tidak ada client data hardcoded.
- Semua waktu disimpan sebagai TIMESTAMPTZ UTC di database dan ditampilkan sesuai timezone client.
- Semua money amount disimpan dalam integer minor unit IDR, bukan float.
- PDF invoice harus immutable. Revisi invoice membuat record dan file baru.
- Migration harus repeatable dan bisa dijalankan dari fresh database.

39.2 Forbidden Code Patterns

Forbidden Pattern	Reason
Hardcode nomor rekening di prompt atau source code	Risiko fatal payment dan tidak bisa audit versioning.
LLM langsung membuat status paid	Melanggar manual payment principle.
Mengirim seluruh chat history ke LLM	Boros token dan risiko privacy. Gunakan sliding window + summary.
Query data tanpa client_id filter	Risiko data client tercampur.
Starsender logic di booking/invoice service	Mengunci core logic ke vendor channel.
Menimpa PDF invoice lama	Menghilangkan audit trail.
Menyimpan amount sebagai float	Risiko salah hitung uang. Ini bukan spreadsheet main-main.
Mengabaikan idempotency webhook	Bisa membuat pesan, invoice, dan notifikasi ganda.
Menghapus rekening lama dari config/database	Invoice lama butuh referensi bank_account_version.
Mengaktifkan payment_gateway flag	Tidak sesuai requirement production saat ini.

39.3 Required Companion Documents

Document	Purpose
AGENT_INSTRUCTION.md	Master instruction untuk AI coding agent sebelum membaca PRD.
DATABASE_SCHEMA.sql	Schema SQL mentah agar implementasi database konsisten dengan ERD.
IMPLEMENTATION_CHECKLIST.md	Checklist verifikasi per modul setelah agent/dev selesai build.

Final Agent Rule

Jika PRD dan output agent bertentangan, PRD ini menang. Jika PRD ambigu, gunakan Section 38. Jika masih ambigu, jangan mengarang: buat TODO eksplisit dan hentikan modul terkait agar tidak menanam bug diam-diam.

40. Token Optimization & Cost Control System

Section ini mendefinisikan sistem penghematan token dan kontrol biaya sebagai bagian inti dari production architecture. AI tidak boleh dipanggil untuk semua hal, tidak boleh menerima seluruh riwayat chat, dan tidak boleh diberi seluruh knowledge base. Sistem harus hemat sejak awal, bukan baru sadar setelah invoice provider AI muncul seperti azab berbentuk billing.

40.1 Objective

- Menurunkan konsumsi token per conversation tanpa mengurangi kualitas jawaban.
- Memastikan biaya AI dapat dilacak per client, conversation, dan model.
- Menghindari pengiriman full chat history ke LLM.
- Menghindari pengiriman seluruh knowledge base ke LLM.
- Menggunakan rule/template/cache sebelum memanggil model AI.
- Menjaga margin agency agar tidak dimakan biaya token diam-diam.

40.2 Token Optimization Flow

Incoming User Message

- > Message Capture to Database
- > Idempotency Check
- > Rule-Based Pre-Classfier
- > Can Answer With Static Template?
 - > YES: Send Template, No LLM Call
 - > NO: Continue
- > Intent Detection
 - > Rule/Small Model First
- > Retrieve RAG Top-K Chunks
- > Load Conversation Summary + Last N Messages
- > Token Budget Guard
- > Model Router
- > LLM Call
- > Safety Guard
- > Save Response + Token Usage Log
- > Optional Cache Save

40.3 Core Token Saving Modules

Module	Function	Required Behavior
Sliding Window Memory	Batasi chat history	Kirim maksimal 4-5 message terakhir + summary, bukan seluruh conversation.
Conversation Summary	Kompresi konteks lama	Summary diperbarui berkala dan dipakai sebagai konteks utama untuk chat panjang.
RAG Top-K Retrieval	Batasi knowledge context	Ambil chunk relevan saja, default <code>top_k=3</code> , <code>max_context_chunks=5</code> .
Rule-Based Intent First	Hindari LLM untuk pesan sederhana	Keyword/regex menangani oke, admin, booking, bukti bayar, terima kasih, dan command umum.
Template Response	Bypass LLM untuk jawaban standar	Payment received, invoice sent,

		handover, data kurang, dan fallback memakai template backend.
Model Routing	Pakai model sesuai task	Intent/summary pakai model murah; chat kompleks pakai main model; fallback pakai stable model.
Response Cache	Reuse jawaban umum	Cache berdasarkan client_id + normalized_question + knowledge_version.
Token Budget Guard	Cegah prompt kebesaran	Jika context melebihi budget, kurangi chunk, ringkas summary, atau fallback ke admin.
Cost Logging	Hitung biaya per client	Simpan input_tokens, output_tokens, total_tokens, model, estimated_cost.

40.4 ai_config.json Addition

Tambahkan blok konfigurasi berikut ke ai_config.json. Nilai model tetap wajib divalidasi ke provider sebelum deploy.

```
{
  "token_optimization": {
    "enabled": true,
    "max_memory_turns": 5,
    "rag_top_k": 3,
    "max_context_chunks": 5,
    "max_chunk_tokens": 500,
    "max_input_tokens": 6000,
    "max_output_tokens": 700,
    "summary_max_tokens": 500,
    "context_overflow_strategy": "compress_then_reduce_chunks_then_handover",
    "use_rule_based_intent_first": true,
    "use_template_response_first": true,
    "response_cache_enabled": true,
    "response_cache_ttl_minutes": 60,
    "cache_key_scope": [
      "client_id",
      "normalized_question",
      "knowledge_version",
      "brand_voice_version"
    ],
    "log_token_usage": true
  },
  "model_routing": {
    "intent": "cheap_fast_model",
```

```

    "summary": "cheap_fast_model",

    "chat": "main_chat_model",

    "safety_review": "stable_model",

    "fallback": "stable_model"

}

}

```

40.5 Rule-Based Bypass Before LLM

Sebelum memanggil LLM, sistem wajib mengecek apakah pesan bisa ditangani oleh rule atau template backend.

Message Pattern	Handling	LLM Call?
"oke", "siap", "baik", "makasih"	Template acknowledgement atau no-op sesuai context.	Tidak
"admin", "mau CS", "mau manusia"	Trigger human_request handover.	Tidak
"sudah bayar", "ini bukti", file/gambar setelah invoice	Payment evidence flow + handover.	Tidak
"mau booking", "ambil seat", "daftar"	Rule booking intent lalu slot filling. LLM hanya jika ambiguity tinggi.	Opsional
Pertanyaan paket/hotel/harga yang butuh data	RAG retrieval + LLM response.	Ya
Komplain/marah/sensitif	Safety classification lalu handover jika perlu.	Opsional

40.6 Sliding Memory & Summary Rule

- Setiap LLM chat request hanya boleh membawa maksimal max_memory_turns terakhir.
- Conversation lama wajib dikompresi menjadi conversation_summary.
- Summary tidak boleh berisi data sensitif yang tidak perlu.
- Summary wajib memuat: paket diminati, pax, status lead, objection penting, data booking yang sudah terkumpul, dan next action.
- Summary diperbarui setelah 8-10 pesan baru atau saat status conversation berubah signifikan.

Example conversation_summary:

User tertarik Paket Umroh Oktober 12 Hari untuk 2 pax. Sudah diberi info harga Rp29.000.000/pax, hotel Makkah Anjum, hotel Madinah Leader Al Muna Kareem. User belum memberi nomor HP.

Status: collecting_booking. Next action: minta nomor HP aktif.

40.7 RAG Top-K & Context Compression Rule

- RAG retrieval wajib filter client_id, document status active, effective date, dan knowledge_version.
- Default retrieval mengambil top_k=3 chunk. Maksimal 5 chunk dikirim ke LLM.
- Chunk dengan score di bawah threshold tidak boleh dikirim ke LLM.
- Jika user bertanya paket spesifik, context dipersempit ke package_id yang relevan.
- Jika ada konflik data, gunakan Section 15 conflict resolution. Jangan kirim dua data konflik ke LLM tanpa label conflict.

40.8 Response Cache & Invalidation

Jawaban umum boleh dicache jika tidak melibatkan data transaksional personal. Cache harus invalid saat knowledge berubah.

Cache Item	Allowed?	Invalidation Rule
FAQ umum	Ya	knowledge_version atau brand_voice_version berubah.
Pertanyaan fasilitas paket	Ya	package_version atau knowledge_version berubah.
Harga paket	Ya dengan hati-hati	price_version berubah atau package effective date berubah.

Invoice total personal	Tidak	Harus dihitung backend per booking.
Payment status	Tidak	Harus dari database/admin.
Rekening pembayaran	Tidak sebagai cache bebas	Harus dari active bank_account_version.

40.9 Token Budget Guard

Setiap LLM request harus melewati budget guard sebelum dikirim ke provider.

if estimated_input_tokens > max_input_tokens:

1. Trim last_messages to lower limit
2. Compress conversation_summary
3. Reduce RAG chunks from 5 -> 3 -> 1
4. Remove non-essential metadata
5. If still too large, trigger safe fallback/handover

- Request yang melebihi max_input_tokens tidak boleh dikirim paksa.
- Output token dibatasi dengan max_output_tokens.
- Prompt harus meminta jawaban ringkas kecuali user butuh detail.
- Semua overflow event dicatat ke token_budget_events atau audit_logs.

40.10 Cost Logging Per Client

Setiap AI call wajib dicatat agar agency bisa menghitung biaya dan margin per client.

```
{
  "client_id": "travel_alfalah",
  "conversation_id": "conv_123",
  "provider": "openai_compatible",
  "model": "main_chat_model",
  "task_type": "chat_response",
  "input_tokens": 1200,
  "output_tokens": 300,
  "total_tokens": 1500,
  "estimated_cost": 0.0021,
  "cache_hit": false,
  "created_at": "2026-06-16T08:00:00+07:00"
}
```

Metric	Purpose
total_tokens_per_client_per_day	Melihat client paling boros token.
cost_per_conversation	Mengukur biaya rata-rata per chat.
cache_hit_rate	Mengukur efektivitas response cache.
llm_call_avoidance_rate	Mengukur berapa banyak pesan selesai tanpa LLM.
rag_context_avg_tokens	Mengontrol panjang context RAG.
overflow_count	Mendeteksi prompt terlalu panjang.

40.11 Database Tables Required

DATABASE_SCHEMA.sql wajib memuat minimal tabel berikut untuk cost control:

Table	Purpose
llm_usage_logs	Mencatat penggunaan token, model, provider, cost, latency, dan cache hit.
response_cache_entries	Menyimpan cache jawaban non-transaksional berdasarkan normalized question dan knowledge version.
token_budget_events	Mencatat context overflow, compression, chunk reduction, dan fallback karena token budget.

40.12 Acceptance Criteria

- LLM tidak menerima full chat history dalam test conversation panjang.
- Pertanyaan sederhana seperti "oke" dan "admin" tidak memanggil LLM.
- RAG hanya mengirim chunk relevan sesuai top_k dan max_context_chunks.
- Cache hit menghindari LLM call untuk FAQ umum yang sama.
- Setiap LLM call menghasilkan record di llm_usage_logs.
- Sistem dapat menampilkan estimasi biaya token per client.
- Jika context terlalu panjang, budget guard melakukan trim/compress/reduce sebelum fallback.
- Invoice, payment status, dan rekening tidak pernah dijawab dari cache bebas.

40.13 Forbidden Patterns

- Jangan mengirim semua message history ke LLM.
- Jangan mengirim seluruh packages.json atau seluruh knowledge base ke LLM.
- Jangan memakai model mahal untuk intent sederhana jika rule cukup.
- Jangan cache data payment status, invoice personal, atau rekening aktif sebagai jawaban bebas.
- Jangan mengabaikan knowledge_version saat membuat cache key.
- Jangan memanggil LLM sebelum idempotency check dan message capture selesai.
- Jangan membuat cost calculation hanya di dashboard; log mentah wajib tersimpan di database.